AGENTX REPLAY · 4P + 4D · 修复后完整矩阵

KV aware 与 Progress 性能报告

> 另有 1 条运行中、失败或中断的尝试，未计入统计；详情见 矩阵完整性。重复轮未全部结束时，跨轮汇总仍会变化。

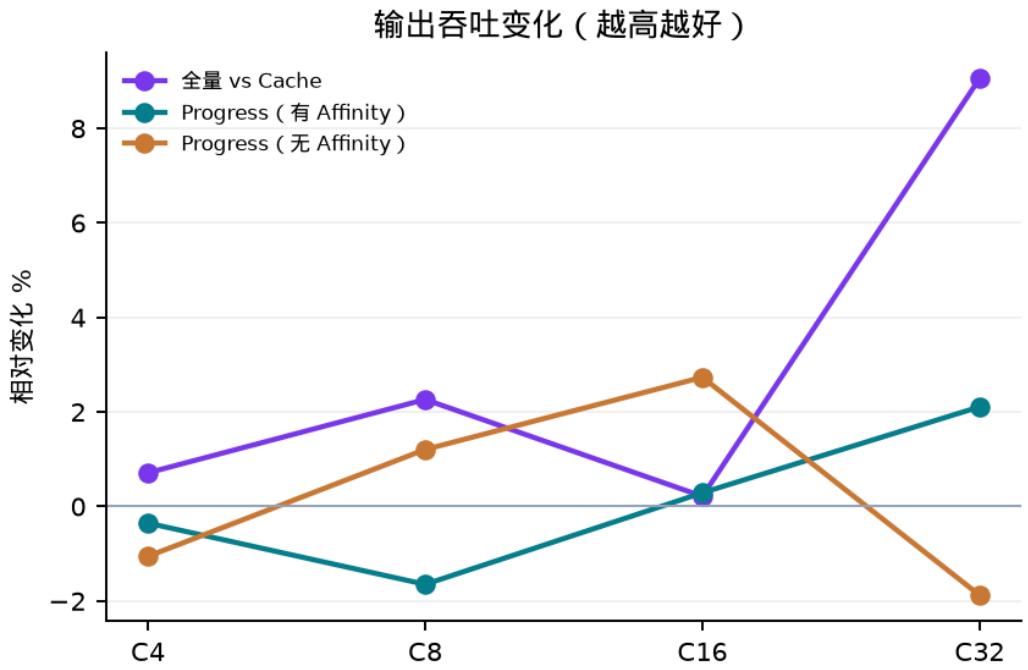
Qwen3-4B-Instruct-2507 / BF16 / TP1 / 每实例 128 GiB KV / NIXL；32 session、730 请求；每轮 input 56,570,112、output 552,859 tokens；4P + 4D。 主视图展示各方案第 1 轮（r1），目前共收集 36 个成功测量窗口。

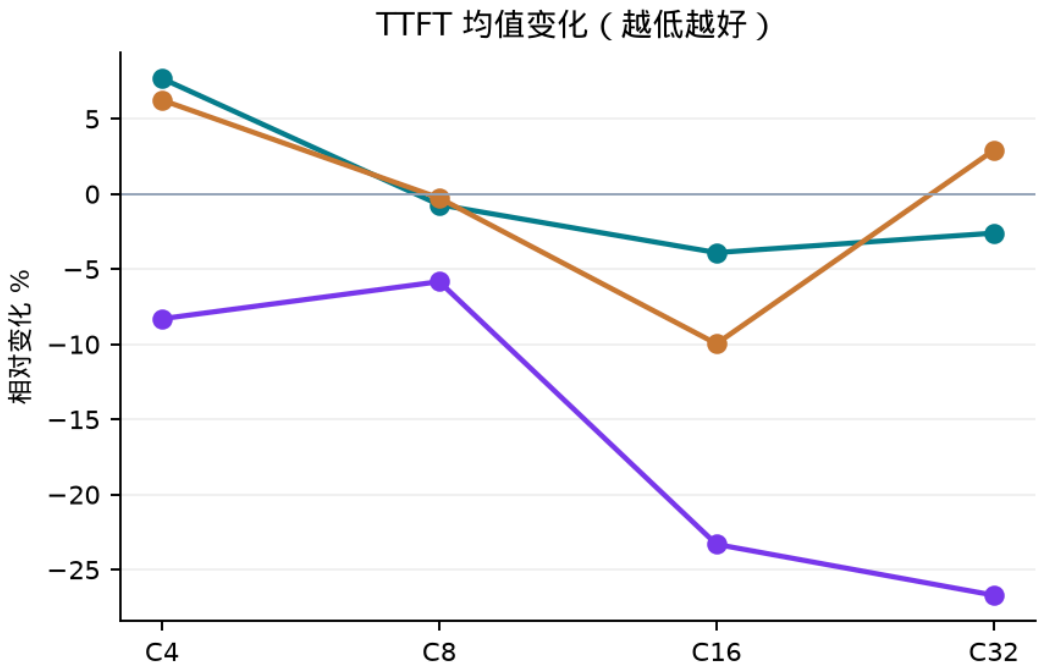
比较固定 Affinity 的 Progress 开关，同时比较无 Affinity 的 Progress 开关，以及全量方案相对 Cache aware。所有比例均以箭头左侧为基准。

先看结果：r1

此处将端到端变化和 P/D 实测成本并列，作为进一步分析的线索；仅凭同时变化不能断定原因。重复轮及方向是否反转见后文。

- **C4：**全量相对 Cache：TTFT 均值 -8.32%，输出吞吐 +0.71%；P 首次新算 -0.32%，P queue -31.40%，P prefill -1.06%。固定开启 Affinity 后加 Progress：TTFT 均值 +7.67%，P queue +271.41%，P prefill +6.43%，P 首次新算 -0.33%，D queue +4.37%。
- **C8：**全量相对 Cache：TTFT 均值 -5.85%，输出吞吐 +2.26%；P 首次新算 -0.50%，P queue -5.85%，P prefill +1.60%。固定开启 Affinity 后加 Progress：TTFT 均值 -0.73%，P queue +278.43%，P prefill -6.07%，P 首次新算 -13.57%，D queue -4.30%。
- **C16：**全量相对 Cache：TTFT 均值 -23.33%，输出吞吐 +0.21%；P 首次新算 -21.68%，P queue -53.08%，P prefill -16.32%。固定开启 Affinity 后加 Progress：TTFT 均值 -3.92%，P queue +14.30%，P prefill -9.18%，P 首次新算 -15.39%，D queue +8.25%。
- **C32：**全量相对 Cache：TTFT 均值 -26.72%，输出吞吐 +9.05%；P 首次新算 -35.69%，P queue -20.62%，P prefill -27.29%。固定开启 Affinity 后加 Progress：TTFT 均值 -2.62%，P queue -3.99%，P prefill -10.81%，P 首次新算 -16.23%，D queue +26.28%。





直接对照：端到端与阶段成本

大字是相对变化，小字是关闭或基准 → 开启或实验的实际值。基准为 0 的百分比不可定义。

并发	比较	input tok/s	output tok/s	total tok/s	TTFT mean ms	TTFT P95 ms	TPOT mean ms	JCT mean s
C4	全量 vs Cache	**+0.71%** 75,985.69 → 76,523.80	**+0.71%** 742.61 → 747.87	**+0.71%** 76,728.29 → 77,271.67	**-8.32%** 348.16 → 319.20	**-14.84%** 1,397.65 → 1,190.23	**+0.32%** 4.33 → 4.34	**-0.45%** 89.65 → 89.25
C4	Progress，有 Affinity	**-0.36%** 76,796.48 → 76,523.80	**-0.36%** 750.53 → 747.87	**-0.36%** 77,547.01 → 77,271.67	**+7.67%** 296.46 → 319.20	**+1.96%** 1,167.35 → 1,190.23	**+0.05%** 4.34 → 4.34	**+0.61%** 88.71 → 89.25
C4	Progress，无 Affinity	**-1.06%** 76,162.03 → 75,354.72	**-1.06%** 744.33 → 736.44	**-1.06%** 76,906.36 → 76,091.16	**+6.24%** 324.60 → 344.85	**+14.66%** 1,206.62 → 1,383.53	**+0.01%** 4.34 → 4.34	**+0.51%** 89.31 → 89.76
C8	全量 vs Cache	**+2.26%** 100,195.31 → 102,460.03	**+2.26%** 979.21 → 1,001.34	**+2.26%** 101,174.52 → 103,461.37	**-5.85%** 366.46 → 345.03	**-11.14%** 1,382.20 → 1,228.27	**+0.63%** 6.06 → 6.09	**-0.26%** 120.35 → 120.04

并发	比较	input tok/s	output tok/s	total tok/s	TTFT mean ms	TTFT P95 ms	TPOT mean ms	JCT mean s
C8	Progress，有 Affinity	**-1.65%** 104,180.97 → 102,460.03	**-1.65%** 1,018.16 → 1,001.34	**-1.65%** 105,199.13 → 103,461.37	**-0.73%** 347.56 → 345.03	**-1.69%** 1,249.42 → 1,228.27	**+0.09%** 6.09 → 6.09	**-1.01%** 121.27 → 120.04
C8	Progress，无 Affinity	**+1.20%** 102,509.08 → 103,741.27	**+1.20%** 1,001.82 → 1,013.86	**+1.20%** 103,510.90 → 104,755.13	**-0.28%** 395.40 → 394.29	**-0.68%** 1,565.09 → 1,554.48	**+2.99%** 5.92 → 6.09	**+1.01%** 120.89 → 122.11
C16	全量 vs Cache	**+0.21%** 114,788.53 → 115,031.85	**+0.21%** 1,121.83 → 1,124.20	**+0.21%** 115,910.36 → 116,156.06	**-23.33%** 543.04 → 416.37	**-36.84%** 2,256.59 → 1,425.33	**+1.13%** 9.43 → 9.53	**-2.76%** 178.56 → 173.63
C16	Progress，有 Affinity	**+0.29%** 114,704.26 → 115,031.85	**+0.29%** 1,121.00 → 1,124.20	**+0.29%** 115,825.26 → 116,156.06	**-3.92%** 433.34 → 416.37	**-16.08%** 1,698.51 → 1,425.33	**-0.88%** 9.62 → 9.53	**-1.41%** 176.11 → 173.63
C16	Progress，无 Affinity	**+2.73%** 110,971.36 → 114,001.10	**+2.73%** 1,084.52 → 1,114.13	**+2.73%** 112,055.88 → 115,115.23	**-9.98%** 521.90 → 469.80	**-19.27%** 2,140.25 → 1,727.75	**-1.42%** 9.55 → 9.41	**-1.29%** 178.57 → 176.27
C32	全量 vs Cache	**+9.05%** 107,729.19 → 117,481.85	**+9.05%** 1,052.84 → 1,148.15	**+9.05%** 108,782.03 → 118,630.00	**-26.72%** 845.41 → 619.56	**-14.11%** 3,227.83 → 2,772.47	**-4.82%** 14.02 → 13.34	**-5.56%** 245.47 → 231.82
C32	Progress，有 Affinity	**+2.10%** 115,060.24 → 117,481.85	**+2.10%** 1,124.48 → 1,148.15	**+2.10%** 116,184.72 → 118,630.00	**-2.62%** 636.21 → 619.56	**+11.96%** 2,476.21 → 2,772.47	**-0.23%** 13.37 → 13.34	**+0.59%** 230.47 → 231.82
C32	Progress，无 Affinity	**-1.88%** 111,727.20 → 109,624.98	**-1.88%** 1,091.91 → 1,071.36	**-1.88%** 112,819.11 → 110,696.34	**+2.89%** 691.44 → 711.44	**+9.34%** 2,547.79 → 2,785.82	**+0.36%** 14.06 → 14.11	**+0.38%** 243.57 → 244.49

P/D 侧成本

本地与外部命中是 token 命中比例；命中率变化用百分点（pp）。传输量为该侧整轮 NIXL 字节；首次新算发生抢占时不包含重算。

P 侧

并发	比较	P 本地命中 %	P 新算 tokens	P queue ms	P prefill ms	P 抢占
C4	全量 vs Cache	**+0.02 pp** 92.74 → 92.76	**-0.32%** 4,109,584.00 → 4,096,560.00	**-31.40%** 17.92 → 12.29	**-1.06%** 202.83 → 200.67	**持平** 0.00 → 0.00
C4	Progress，有 Affinity	**+0.02 pp** 92.73 → 92.76	**-0.33%** 4,110,256.00 → 4,096,560.00	**+271.41%** 3.31 → 12.29	**+6.43%** 188.54 → 200.67	**持平** 0.00 → 0.00
C4	Progress，无 Affinity	**+0.26 pp** 92.76 → 93.03	**-3.66%** 4,092,912.00 → 3,943,216.00	**+47.64%** 5.31 → 7.85	**-0.79%** 190.88 → 189.38	**持平** 0.00 → 0.00
C8	全量 vs Cache	**+0.04 pp** 92.72 → 92.76	**-0.50%** 4,118,384.00 → 4,097,776.00	**-5.85%** 14.80 → 13.93	**+1.60%** 199.42 → 202.62	**持平** 0.00 → 0.00
C8	Progress，有 Affinity	**+1.14 pp** 91.62 → 92.76	**-13.57%** 4,741,104.00 → 4,097,776.00	**+278.43%** 3.68 → 13.93	**-6.07%** 215.71 → 202.62	**持平** 0.00 → 0.00

并发	比较	P 本地命中 %	P 新算 tokens	P queue ms	P prefill ms	P 抢占
C8	Progress，无 Affinity	**+1.00 pp** 91.56 → 92.55	**-11.80%** 4,776,688.00 → 4,213,040.00	**+60.13%** 6.50 → 10.42	**-1.74%** 211.75 → 208.06	**持平** 0.00 → 0.00
C16	全量 vs Cache	**+2.14 pp** 90.12 → 92.26	**-21.68%** 5,589,552.00 → 4,377,632.00	**-53.08%** 70.58 → 33.12	**-16.32%** 262.79 → 219.91	**持平** 0.00 → 0.00
C16	Progress，有 Affinity	**+1.41 pp** 90.85 → 92.26	**-15.39%** 5,173,936.00 → 4,377,632.00	**+14.30%** 28.97 → 33.12	**-9.18%** 242.13 → 219.91	**持平** 0.00 → 0.00
C16	Progress，无 Affinity	**+1.90 pp** 90.46 → 92.36	**-19.89%** 5,396,720.00 → 4,323,440.00	**+2.82%** 40.37 → 41.51	**-13.70%** 252.83 → 218.19	**持平** 0.00 → 0.00
C32	全量 vs Cache	**+4.22 pp** 88.18 → 92.40	**-35.69%** 6,687,136.00 → 4,300,560.00	**-20.62%** 219.17 → 173.98	**-27.29%** 315.52 → 229.41	**持平** 0.00 → 0.00
C32	Progress，有 Affinity	**+1.47 pp** 90.92 → 92.40	**-16.23%** 5,133,872.00 → 4,300,560.00	**-3.99%** 181.22 → 173.98	**-10.81%** 257.22 → 229.41	**持平** 0.00 → 0.00
C32	Progress，无 Affinity	**+0.22 pp** 91.93 → 92.14	**-2.69%** 4,567,584.00 → 4,444,720.00	**+4.79%** 165.59 → 173.52	**+0.56%** 232.04 → 233.33	**持平** 0.00 → 0.00

D 侧

并发	比较	D 本地命中 %	D 外部命中 %	D 新算 tokens	D queue ms	D prefill ms	D 传输 GiB	D 抢占
C4	全量 vs Cache	**+2.48 pp** 90.55 → 93.03	**-2.48 pp** 9.45 → 6.97	**持平** 0.00 → 0.00	**-36.71%** 73.44 → 46.48	**+0.10%** 7.20 → 7.20	**-26.21%** 733.91 → 541.52	**持平** 0.00 → 0.00
C4	Progress，有 Affinity	**+0.00 pp** 93.03 → 93.03	**+0.00 pp** 6.97 → 6.97	**持平** 0.00 → 0.00	**+4.37%** 44.53 → 46.48	**+0.87%** 7.14 → 7.20	**+0.00%** 541.52 → 541.52	**持平** 0.00 → 0.00
C4	Progress，无 Affinity	**-0.93 pp** 90.64 → 89.71	**+0.93 pp** 9.36 → 10.29	**持平** 0.00 → 0.00	**+26.12%** 69.76 → 87.98	**+2.75%** 7.10 → 7.29	**+9.92%** 726.89 → 799.03	**持平** 0.00 → 0.00
C8	全量 vs Cache	**+4.95 pp** 87.92 → 92.87	**-4.95 pp** 12.08 → 7.13	**持平** 0.00 → 0.00	**-37.79%** 85.84 → 53.40	**+0.71%** 10.97 → 11.05	**-40.98%** 938.71 → 554.05	**持平** 0.00 → 0.00
C8	Progress，有 Affinity	**+0.12 pp** 92.75 → 92.87	**-0.12 pp** 7.25 → 7.13	**持平** 0.00 → 0.00	**-4.30%** 55.80 → 53.40	**+0.90%** 10.95 → 11.05	**-1.67%** 563.46 → 554.05	**持平** 0.00 → 0.00
C8	Progress，无 Affinity	**+1.56 pp** 86.15 → 87.70	**-1.56 pp** 13.85 → 12.30	**持平** 0.00 → 0.00	**-9.94%** 104.85 → 94.43	**+3.53%** 10.70 → 11.07	**-11.25%** 1,076.29 → 955.19	**持平** 0.00 → 0.00
C16	全量 vs Cache	**+7.82 pp** 84.65 → 92.47	**-7.82 pp** 15.35 → 7.53	**持平** 0.00 → 0.00	**-38.82%** 112.07 → 68.57	**+0.56%** 17.68 → 17.78	**-50.94%** 1,192.44 → 585.01	**持平** 0.00 → 0.00

并发	比较	D 本地命中 %	D 外部命中 %	D 新算 tokens	D queue ms	D prefill ms	D 传输 GiB	D 抢占
C16	Progress，有 Affinity	**-0.10 pp** 92.57 → 92.47	**+0.10 pp** 7.43 → 7.53	**持平** 0.00 → 0.00	**+8.25%** 63.34 → 68.57	**-1.95%** 18.13 → 17.78	**+1.41%** 576.87 → 585.01	**持平** 0.00 → 0.00
C16	Progress，无 Affinity	**-0.91 pp** 84.37 → 83.46	**+0.91 pp** 15.63 → 16.54	**持平** 0.00 → 0.00	**-7.63%** 126.17 → 116.54	**-13.85%** 20.37 → 17.55	**+5.83%** 1,213.92 → 1,284.68	**持平** 0.00 → 0.00
C32	全量 vs Cache	**+12.70 pp** 77.77 → 90.47	**-12.70 pp** 22.23 → 9.53	**持平** 0.00 → 0.00	**-50.52%** 187.32 → 92.68	**-8.50%** 27.34 → 25.02	**-57.13%** 1,726.96 → 740.41	**持平** 0.00 → 0.00
C32	Progress，有 Affinity	**-1.76 pp** 92.23 → 90.47	**+1.76 pp** 7.77 → 9.53	**持平** 0.00 → 0.00	**+26.28%** 73.39 → 92.68	**-0.49%** 25.14 → 25.02	**+22.72%** 603.32 → 740.41	**持平** 0.00 → 0.00
C32	Progress，无 Affinity	**-0.58 pp** 76.44 → 75.86	**+0.58 pp** 23.56 → 24.14	**持平** 0.00 → 0.00	**+4.10%** 163.74 → 170.46	**-3.44%** 27.45 → 26.51	**+2.46%** 1,830.59 → 1,875.57	**持平** 0.00 → 0.00

TTFT 包含客户端发出请求、router 处理和选点、P queue、P prefill、P/D 协调与传输、D 排队和首次执行以及结果返回；部分过程可能重叠。P prefill 是首次调度至首次输出的墙钟时间，含非 GPU 等待，不等于纯 kernel 时间。只有独立逐请求路由证据时，才能将缓存、队列变化归因到具体选点。

反常点：两轮是否重复出现

固定 Affinity 状态，对比 Progress 关闭 → 开启；每格分别列出匹配轮次的相对变化和绝对值。若 TTFT 与 P queue、新算量或 D 传输耗时方向不一致，说明不能只用其中一项解释整条请求路径。

并发	对照	配对轮数	TTFT mean ms	TTFT P99 ms	P queue ms	P prefill ms	P 首次新算	D queue ms	D NIXL xfer ms	D 传输 GiB
C4	Progress，有 Affinity	2	r1: +7.67% 296.46 → 319.20 r2: +4.97% 297.79 → 312.58	r1: +10.23% 2,405.26 → 2,651.33 r2: +12.15% 2,450.65 → 2,748.36	r1: +271.41% 3.31 → 12.29 r2: +417.76% 1.86 → 9.62	r1: +6.43% 188.54 → 200.67 r2: +2.91% 190.78 → 196.34	r1: -0.33% 4,110,256.00 → 4,096,560.00 r2: -1.92% 4,109,488.00 → 4,030,736.00	r1: +4.37% 44.53 → 46.48 r2: -1.09% 46.69 → 46.18	r1: +5.11% 36.74 → 38.61 r2: -1.17% 39.10 → 38.64	r1: +0.00% 541.52 → 541.52 r2: +6.19% 541.52 → 575.02
C4	Progress，无 Affinity	2	r1: +6.24% 324.60 → 344.85 r2: +3.86% 330.54 → 343.30	r1: +19.01% 2,644.44 → 3,147.16 r2: +7.30% 2,761.92 → 2,963.51	r1: +47.64% 5.31 → 7.85 r2: -65.75% 7.67 → 2.63	r1: -0.79% 190.88 → 189.38 r2: +3.97% 189.43 → 196.95	r1: -3.66% 4,092,912.00 → 3,943,216.00 r2: +3.89% 4,047,664.00 → 4,204,976.00	r1: +26.12% 69.76 → 87.98 r2: +6.66% 76.56 → 81.66	r1: +29.43% 61.92 → 80.14 r2: +7.38% 68.80 → 73.88	r1: +9.92% 726.89 → 799.03 r2: -0.58% 780.46 → 775.94
C8	Progress，有 Affinity	2	r1: -0.73% 347.56 → 345.03 r2: -4.28% 366.73 → 351.04	r1: -2.59% 3,100.65 → 3,020.44 r2: -20.84% 3,563.21 → 2,820.76	r1: +278.43% 3.68 → 13.93 r2: +16.82% 8.89 → 10.39	r1: -6.07% 215.71 → 202.62 r2: -5.36% 218.34 → 206.63	r1: -13.57% 4,741,104.00 → 4,097,776.00 r2: -11.97% 4,739,056.00 → 4,171,888.00	r1: -4.30% 55.80 → 53.40 r2: -11.88% 66.54 → 58.63	r1: -6.12% 42.03 → 39.46 r2: -10.02% 50.04 → 45.03	r1: -1.67% 563.46 → 554.05 r2: -1.55% 583.77 → 574.70

并发	对照	配对轮数	TTFT mean ms	TTFT P99 ms	P queue ms	P prefill ms	P 首次新算	D queue ms	D NIXL xfer ms	D 传输 GiB
C8	Progress，无 Affinity	2	r1: -0.28% 395.40 → 394.29 r2: -2.27% 406.08 → 396.87	r1: -4.13% 3,179.60 → 3,048.25 r2: -14.44% 3,447.73 → 2,949.95	r1: +60.13% 6.50 → 10.42 r2: +64.52% 7.20 → 11.85	r1: -1.74% 211.75 → 208.06 r2: -7.19% 227.97 → 211.57	r1: -11.80% 4,776,688.00 → 4,213,040.00 r2: -8.53% 4,887,776.00 → 4,470,896.00	r1: -9.94% 104.85 → 94.43 r2: +3.55% 96.07 → 99.48	r1: -11.69% 90.91 → 80.27 r2: +4.35% 81.89 → 85.45	r1: -11.25% 1,076.29 → 955.19 r2: +5.70% 947.44 → 1,001.41
C16	Progress，有 Affinity	2	r1: -3.92% 433.34 → 416.37 r2: -8.64% 433.81 → 396.34	r1: -11.77% 3,863.22 → 3,408.70 r2: -17.21% 3,657.29 → 3,028.03	r1: +14.30% 28.97 → 33.12 r2: -6.60% 33.30 → 31.10	r1: -9.18% 242.13 → 219.91 r2: -9.94% 237.52 → 213.91	r1: -15.39% 5,173,936.00 → 4,377,632.00 r2: -17.87% 5,219,392.00 → 4,286,848.00	r1: +8.25% 63.34 → 68.57 r2: -15.63% 69.67 → 58.78	r1: +13.97% 39.45 → 44.96 r2: -23.72% 46.70 → 35.62	r1: +1.41% 576.87 → 585.01 r2: -4.74% 614.41 → 585.31
C16	Progress，无 Affinity	2	r1: -9.98% 521.90 → 469.80 r2: -1.83% 455.16 → 446.84	r1: -14.78% 3,699.16 → 3,152.36 r2: +5.74% 3,160.83 → 3,342.29	r1: +2.82% 40.37 → 41.51 r2: +7.75% 27.83 → 29.99	r1: -13.70% 252.83 → 218.19 r2: -4.44% 221.82 → 211.97	r1: -19.89% 5,396,720.00 → 4,323,440.00 r2: -11.42% 4,846,768.00 → 4,293,088.00	r1: -7.63% 126.17 → 116.54 r2: -3.10% 114.52 → 110.98	r1: -6.99% 100.99 → 93.93 r2: -3.32% 90.26 → 87.27	r1: +5.83% 1,213.92 → 1,284.68 r2: -2.79% 1,174.55 → 1,141.78
C32	Progress，有 Affinity	2	r1: -2.62% 636.21 → 619.56 r2: -6.31% 653.85 → 612.56	r1: -6.38% 6,383.86 → 5,976.87 r2: +11.83% 5,690.90 → 6,364.33	r1: -3.99% 181.22 → 173.98 r2: -8.32% 185.99 → 170.52	r1: -10.81% 257.22 → 229.41 r2: -11.20% 259.65 → 230.56	r1: -16.23% 5,133,872.00 → 4,300,560.00 r2: -21.52% 5,389,680.00 → 4,230,048.00	r1: +26.28% 73.39 → 92.68 r2: -11.34% 83.87 → 74.36	r1: +42.39% 38.68 → 55.07 r2: -23.37% 47.97 → 36.76	r1: +22.72% 603.32 → 740.41 r2: -4.98% 641.91 → 609.92
C32	Progress，无 Affinity	2	r1: +2.89% 691.44 → 711.44 r2: -2.15% 744.15 → 728.18	r1: +3.89% 5,728.05 → 5,951.04 r2: +2.26% 6,054.60 → 6,191.53	r1: +4.79% 165.59 → 173.52 r2: +11.36% 171.75 → 191.26	r1: +0.56% 232.04 → 233.33 r2: -7.19% 252.06 → 233.94	r1: -2.69% 4,567,584.00 → 4,444,720.00 r2: -20.41% 5,362,208.00 → 4,267,568.00	r1: +4.10% 163.74 → 170.46 r2: -11.00% 185.06 → 164.71	r1: +4.34% 129.16 → 134.77 r2: -12.65% 148.51 → 129.72	r1: +2.46% 1,830.59 → 1,875.57 r2: -5.75% 1,869.89 → 1,762.38

> 本次正式性能轮没有逐候选实时评分和 client→engine 全链路逐请求关联；因此表中是可复核的现象和原因线索，不能断言某次选点由 Progress 造成。D queue 可能与 NIXL 传输重叠，xfer/post 的独立计数和耗时不能再与 D queue 相加。

重复实验与稳定性

只将同编号轮次配对，例如 r2 对 r2；未配对的轮次不计入增量。每项展示各轮原值和相对变化、可比较的配对样本数、各轮变化的算术均值，以及正负方向是否反转。基准为 0 的比例不可定义。

跨轮均值是各轮统计值的均值：例如"TTFT P95 的跨轮均值"不是把全部请求合并后的 P95。方案的各轮原值及样本数见汇总 CSV，逐 worker 原值保留所有轮次。

下载各方案逐轮汇总 · 下载同轮次配对与变化 · 下载所有轮次完整窗口指标

数据口径与复现

- input/output/total token/s 按整轮回放时间计算；input 包含缓存复用，不能当作实际新算。
- TTFT、TPOT 按请求统计；JCT 为 task 获得并发槽到完成的时长，每组 32 个 task，P95/P99 应谨慎解读。
- worker 阶段时延的 P50/P95/P99 根据 Prometheus histogram 给出所在桶范围，不冒充精确分位数。
- 首次新算 token 和调度 token 是计算工作量代理，不是 FLOPs；发生抢占时第一次统计不包含后续重算。